

Lec4: 点估计(一)

张伟平

September 24, 2009

§1 引言

数理统计的任务是用样本去推断总体. 参数估计是统计推断的一种重要形式. 设有参数分布族 $\mathcal{F} = \{F_\theta, \theta \in \Theta\}$, 其中 Θ 是参数空间, F_θ 的分布形式已知, 但其分布与未知参数 θ 有关. X_1, \dots, X_n 是从总体 F_θ 中抽出的简单随机样本. 我们的任务是要利用样本对未知参数 θ 或其函数 $g(\theta)$ 作出估计. 所以在参数分布族场合, 把参数理解为定义在参数空间 Θ 上的实值函数 $g(\theta)$, 一个重要的特例是 $g(\theta) = \theta$. 例如, X_1, \dots, X_n i.i.d. $\sim N(a, \sigma^2)$, 记 $\theta = (\mu, \sigma^2)$, 我们希望利用样本对 μ 和 σ^2 或其函数 $g(\theta) = \mu/\sigma^2$ 的值作出估计, 这就是参数估计问题.

有时样本分布族 $\mathcal{F} = \{F\}$ 是非参数分布族, 其中 F 的分布形式未知, 但其均值、方差等都是刻画总体某方面性质的量, 也都是参数. 因此在非参数分布族场合, 把参数理解为分布族 \mathcal{F} 上的泛函 $g(F)$. 我们希望利用样本对 $g(F)$, 例如 $g(F)$ 为总体均值、方差或中位数等, 作出估计, 这也属于参数估计问题. 例如, 我们从某城市居民中抽取一部分, 对其年收入作调查, 获得样本 X_1, \dots, X_n , 要对该城市居民的年人均收入作出估计, 就属于这类问题.

参数估计(Parameter estimation)问题常有两类: 点估计和区间估计. 点估计就是用样本函数的一个具体数值去估计一个未知参数. 区间估计就是用样本函数的两个值构成的区间去估计未知参数的取值范围.

定义 1. 设 $\mathbf{X} = (X_1, \dots, X_n)$ 为从某总体中抽取的样本, $\hat{g}(\mathbf{X}) = \hat{g}(X_1, \dots, X_n)$ 是样本的函数, 用 $\hat{g}(\mathbf{X})$ 作为 $g(\theta)$ 的估计, 称为点估计(Point estimation).

本章我们将首先讨论点估计的方法. 对于同一个未知参数 θ (为方便计, 此处以 $g(\theta) = \theta$ 为例)的估计量可以有很多. 例如, 设 X_1, \dots, X_n 是取自某总体 $F \in \mathcal{F}$ 的一组简单样本. 对此总体的均值 $\theta = E_F(X)$ 可以给出几个估计量:

$$\begin{aligned}\hat{\theta}_1 &= \bar{X} = \frac{1}{n}(X_1 + \dots + X_n), \\ \hat{\theta}_2 &= \frac{1}{2}(X_{(1)} + X_{(n)}), \\ \hat{\theta}_3 &= m_{1/2}.\end{aligned}$$

其中 $X_{(1)}$ 和 $X_{(n)}$ 为样本最小和最大次序统计量, $m_{1/2}$ 为样本中位数. 还可以给出其它的估计量. 这就产生一个问题: 我们采用哪一个估计量作为 θ 的点估计较好呢? 这就涉及到评价一个估计量优劣的标准问题. 标准不同, 回答也不同. 在经典估计理论中, 用来评价估计量好坏的标准有: 无偏性、有效性、相合性和渐近正态性等, 以及在某种标准下寻求最好的估计.

§2 判断估计量的优良性标准

1. 无偏性

我们在评价估计量好坏时,一般总希望估计量 $\hat{\theta}(\mathbf{X})$ 的平均值与 θ 越接近越好,即 $E(\hat{\theta}(\mathbf{X}) - \theta)$ 越小越好. 由于 $\hat{\theta}(\mathbf{X})$ 是随机变量, $\hat{\theta}(\mathbf{X})$ 的值有时比 θ 的值大,有时比 θ 的值小,我们希望 $\hat{\theta}(\mathbf{X})$ 在大量重复使用时,在平均意义下 $\hat{\theta}(\mathbf{X})$ 与 θ 的偏差很小. 期望值 $E(\hat{\theta}(\mathbf{X}) - \theta) = 0$,时就得到无偏性的概念. 将其一般化,用 $g(\theta)$ 代替 θ ,用 $\hat{g}(\mathbf{X})$ 代替 $\hat{\theta}(\mathbf{X})$,得到如下定义:

定义 1. 设 $\mathbf{X} = (X_1, \dots, X_n)$ 为从总体 $\{F_\theta, \theta \in \Theta\}$ 中抽取的样本, $g(\theta)$ 是定义于参数空间 Θ 上的已知函数. $\hat{g}(\mathbf{X}) = \hat{g}(X_1, \dots, X_n)$ 是 $g(\theta)$ 的一个估计量, 如果

$$E_\theta(\hat{g}(\mathbf{X})) = g(\theta), \quad \text{对任何 } \theta \in \Theta$$

则称 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的一个无偏估计量 (*Unbiased estimation*). 记 $\hat{g}(\mathbf{X}) = \hat{g}_n(\mathbf{X})$, 若

$$\lim_{n \rightarrow \infty} E_\theta(\hat{g}_n(\mathbf{X})) = g(\theta), \quad \text{对任何 } \theta \in \Theta$$

则称 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta)$ 的渐近无偏估计 (*Asymptotically unbiased estimation*).

无偏性的含意有两个: 第一个含意是无系统偏差. 由于样本的随机性, $\hat{g}(\mathbf{X})$ 是样本的函数, 因此它是一随机变量, 用估计量 $\hat{g}(\mathbf{X})$ 去估计 $g(\theta)$, 对某些样本, $\hat{g}(\mathbf{X})$ 与 $g(\theta)$ 相比, 时而偏低; 对另一些样本, $\hat{g}(\mathbf{X})$ 时而偏高; 无偏性表示, 把这些正负偏差在概率上平均起来, 其值为0. 如用一杆秤去称东西, 误差的来源有二: (i) 这杆秤自身结构上有问题. 用它称东西总是倾向于偏高或总是倾向于偏低, 这属于系统误差. (ii) 另一种误差是随机误差, 由不可控制的因素产生, 如温度、湿度和工作人员心理波动等影响造成的, 这属于随机误差. 无偏性相当于要求无系统误差. 随机误差总是存在的, 大量重复使用无偏估计, 误差有时为正, 有时为负, 但随机误差可以正负相抵消.

无偏性的另一个含意是: 要求估计量大量重复使用, 在多次重复使用下给出接近真值 $g(\theta)$ 的估计. 设想这样一种情况: 每天抽样对 $g(\theta)$ 进行估计, 第 i 天的样本为 $\mathbf{X}^{(i)} = (X_1^{(i)}, \dots, X_n^{(i)})$, 估计值为 $\hat{g}(\mathbf{X}^{(i)})$, 一共作了 n 天. 设 $\mathbf{X}^{(1)}, \dots, \mathbf{X}^{(n)}$ 是独立同分布的样本, 如 $\hat{g}(\mathbf{X})$ 有无偏性, 按大数定律有

$$P\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n \hat{g}(\mathbf{X}^{(i)}) = g(\theta)\right) = 1$$

就是说, 尽管一次估计结果 $\hat{g}(\mathbf{X}^{(i)})$ 不一定恰好等于 $g(\theta)$, 但在大量重复使用时, 多次估计的算术平均值, 可以任意接近 $g(\theta)$. 如果这一估计量 $\hat{g}(\mathbf{X})$ 只使用一次, 无偏性这个概念就失去意义.

在点估计理论中, 目前无偏性仍占有重要的地位. 除了历史因素外, 还有两个原因. 一是无偏性的要求只涉及一阶矩(均值), 在数学处理时较方便. 二是在没有其它合理准则可循时, 人们心理上觉得: 一个具有无偏性的估计, 总比没有这种性质的估计要好些.

定义 2. 设 X_1, \dots, X_n 是取自期望为 μ , 方差为 σ^2 的总体的一个样本. 显然样本均值 \bar{X} 是 μ 的无偏估计. 证明样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的无偏估计.

证 显然

$$E(S^2) = \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right] = \frac{n}{n-1} [E(X_1^2) - E(\bar{X}^2)]$$

$$= \frac{n}{n-1} \left[(\sigma^2 + \mu^2) - (\sigma^2/n + \mu^2) \right] = \sigma^2,$$

故样本方差 S^2 是 σ^2 的无偏估计.

2. 有效性

在应用中, 同一个参数的无偏估计常常不止一个, 那么选用哪一个无偏估计更好呢? 为了解决好这一问题, 就要讨论估计量的有效性(efficiency). 设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 为 θ 的两个无偏估计, 由无偏性可知它们的一阶矩相等, 我们比较它们的二阶中心矩—方差, 方差越小越好.

定义 3. 设 $\hat{g}_1(\mathbf{X}) = \hat{g}_1(X_1, \dots, X_n)$ 和 $\hat{g}_2(\mathbf{X}) = \hat{g}_2(X_1, \dots, X_n)$ 为 $g(\theta)$ 的两个不同无偏估计量, 若

$$D_\theta(\hat{g}_1(\mathbf{X})) \leq D_\theta(\hat{g}_2(\mathbf{X})), \quad \text{对一切 } \theta \in \Theta,$$

且至少存在一个 $\theta \in \Theta$, 使得严格不等号成立, 则称估计量 $\hat{g}_1(\mathbf{X})$ 比 $\hat{g}_2(\mathbf{X})$ 有效.

从这个定义出发可以看出, 在均值相等的条件下, 方差越小的估计量越有效. 例如, X_1, \dots, X_n 是取自总体 F 的一个简单样本, 设总体均值 μ 和总体方差 σ^2 都存在, 则 $\hat{\theta}_1 = X_1$ 和 $\hat{\theta}_2 = \bar{X}$ 都是总体均值 μ 的无偏估计量, 它们的方差分别是

$$D(\hat{\theta}_1) = \sigma^2, \quad D(\hat{\theta}_2) = \frac{1}{n}\sigma^2.$$

后者更小, 可见 \bar{X} 比 X_1 更有效, 且 n 越大, \bar{X} 对 μ 的估计就越有效. 这就是在物体的称重问题中, 为什么我们要将物体称 n 次, 用其平均值作为物重的理由.

3. 相合性

大量实践表明, 随着样本容量 n 的增加, 估计量 $\hat{g}(\mathbf{X}) = \hat{g}(X_1, \dots, X_n)$ 与被估计参数 $g(\theta)$ 的偏差越来越小, 这是一个良好估计量应具有的性质. 试想, 若不然, 无论作多少次试验, 也不能把 $g(\theta)$ 估计到任意指定的精确程度, 这样估计量显然是不可取的.

定义 4. 设对每个自然数 n , $\hat{g}_n(\mathbf{X}) = \hat{g}_n(X_1, \dots, X_n)$ 是 $g(\theta)$ 一个估计量, 若 $\hat{g}_n(\mathbf{X})$ 依概率收敛到 $g(\theta)$, 即对任何 $\theta \in \Theta$ 及 $\varepsilon > 0$ 有

$$\lim_{n \rightarrow \infty} P_\theta(|\hat{g}_n(\mathbf{X}) - g(\theta)| \geq \varepsilon) = 0,$$

则称 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta)$ 的弱相合估计 (Weakly consistent estimation). 若对任何 $\theta \in \Theta$ 有

$$P_\theta \left(\lim_{n \rightarrow \infty} \hat{g}_n(\mathbf{X}) = g(\theta) \right) = 1,$$

则称 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta)$ 的强相合估计 (Strongly consistent estimation). 若 $r > 0$ 和对任何 $\theta \in \Theta$, 有

$$\lim_{n \rightarrow \infty} E_\theta |\hat{g}_n(\mathbf{X}) - g(\theta)|^r = 0,$$

称 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta)$ 的 r 阶矩相合估计 (Consistent estimation in r 'th mean). 当 $r = 2$ 时称为均方相合估计 (Consistent estimation in quadratic mean).

估计量的相合性是对大样本问题提出的要求, 是估计量的一种大样本性质.

由概率论中关于这几种收敛性的关系, 可知上述三种相合性有如下关系: 强相合 \implies 弱相合, 反之不必对; 对任何 $r > 0$ 有: r 阶矩相合 \implies 弱相合, 反之不必对. 又强相合与 r 阶矩相合之间没有包含关系.

估计量的大样本性质, 还有渐近正态性, 我们将在本章后面有关的小节中给出定义.

§3 矩估计

一、矩法和矩估计量

设 X_1, \dots, X_n 是从总体 F 中抽取的简单随机样本. 这时, 样本矩可用来估计 F 的相应的总体矩. 即总体 k 阶原点矩 $\alpha_k = E(X^k)$ 的矩估计量是相应的样本 k 阶原点矩

$$a_{nk} = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots, \quad (3.1)$$

特别总体均值 $\alpha_1 = E(X)$ 的矩估计量是样本均值 $a_{n1} = \bar{X}$.

总体 k 阶中心矩 $\mu_k = E(X - E(X))^k$ 的矩估计量是相应的样本 k 阶中心矩

$$m_{nk} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 1, 2, \dots, \quad (3.2)$$

特别总体方差 $\mu_2 = E(X - EX)^2$ 的矩估计量是 $m_{n2} = S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 它与样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 只差一个常数因子.

用 a_{nk} , m_{nk} 分别估计 α_k 和 μ_k 是一种基于直观的方法, 它的依据是: a_{nk} 是 α_k 的无偏估计, 即

$$Ea_{nk} = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \frac{1}{n} \sum_{i=1}^n \alpha_k = \alpha_k. \quad (3.3)$$

但用 m_{nk} 估计 μ_k , 一般不是无偏的, 当样本大小 n 较大时, 偏差不显著, 且必要时可作一些修正, 使之成为无偏估计. 请看下例:

例1. 设 $\mu_2 = \sigma^2$ 是总体方差, 则 $S_n^2 = m_{n2}$ 不是 σ^2 的无偏估计.

证 由例可知

$$\begin{aligned} E(S_n^2) &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= \frac{n-1}{n} E(S^2) = \frac{n-1}{n} \sigma^2. \end{aligned} \quad (3.4)$$

因而 m_{n2} 不是 σ^2 的无偏估计, 且是系统地偏低. 将其修正, 只须用

$$m_{n2}^* = \frac{n}{n-1} m_{n2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = S^2 \quad (3.5)$$

代替 m_{n2} , 就得到 $E(m_{n2}^*) = E(S^2) = \sigma^2$, 即 S^2 为总体方差的无偏估计. 这就是我们用 S^2 作为样本方差的定义, 而不用 m_{n2} 的理由所在. 但当 $k \geq 4$, 就不能通过这样简单的修正得出 μ_k 的无偏估计.

一般, 样本的 k 阶中心矩可以用样本的原点矩表出(令 $a_{n0} = 1$):

$$\begin{aligned} m_{nk} &= \frac{1}{n} \sum_{i=1}^n (X_i - a_{n1})^k = \frac{1}{n} \sum_{i=1}^n \sum_{r=0}^k \binom{k}{r} (-1)^{k-r} X_i^r a_{n1}^{k-r} \\ &= \sum_{r=0}^k \left(\frac{1}{n} \sum_{i=1}^n X_i^r \right) (-1)^{k-r} \binom{k}{r} a_{n1}^{k-r} \end{aligned}$$

$$= \sum_{r=0}^k (-1)^{k-r} \binom{k}{r} a_{nr} a_{n1}^{k-r}, \quad (3.6)$$

下面给出矩法及矩估计量的定义.

定义 1. 设有总体分布族 $\{F_\theta, \theta \in \Theta\}$, Θ 是参数空间, $g(\theta)$ 是定义在 Θ 上的参数 θ 的函数, 它可以表为总体分布的某些矩的函数, 即

$$g(\theta) = G(\alpha_1, \dots, \alpha_k; \mu_1, \dots, \mu_s). \quad (3.7)$$

设 $\mathbf{X} = (X_1, \dots, X_n)$ 是从上述分布族中抽取的简单样本, 用 a_{ni} 和 m_{nj} 分别代替 (3.7) 式中的 α_i 和 μ_j 得

$$\hat{g}(\mathbf{X}) = G(a_{n1}, \dots, a_{nk}; m_{n1}, \dots, m_{ns}), \quad (3.8)$$

其中 a_{ni} 是 α_i 的矩估计量, m_{nj} 是 μ_j 的矩估计量, 则 $\hat{g}(\mathbf{X})$ 作为 $g(\theta)$ 的估计量, 称为 $g(\theta)$ 的矩估计量 (Moment estimate). 这种求矩估计量的方法称为矩法 (Moment method of estimation).

二、若干例子

例2. 设 X_1, \dots, X_n 是从具有成功概率 θ 的两点分布总体 $b(1, \theta)$ 中抽取的简单样本, 求 θ 和 $g(\theta) = \theta(1 - \theta)$ 的矩估计.

解 设 $X \sim b(1, \theta)$, 即有 $P(X = x) = \theta^x (1 - \theta)^{1-x}$. 由于 $E(X) = \theta$, 因此 θ 的矩估计就是 $\hat{\theta}(X_1, \dots, X_n) = \bar{X}$, 而 $g(\theta)$ 的矩估计是

$$\hat{g}(X_1, \dots, X_n) = \bar{X}(1 - \bar{X}).$$

例3. 设 X_1, \dots, X_n i.i.d. \sim 均匀分布 $U(\theta_1, \theta_2)$, 参数 $\theta = (\theta_1, \theta_2)$, 其中 $-\infty < \theta_1 < \theta_2 < +\infty$. 求 θ_1 和 θ_2 的矩估计量.

解 设 $X \sim U(\theta_1, \theta_2)$, 由均匀分布的性质可知

$$\begin{aligned} E(X) &= \alpha_1 = (\theta_1 + \theta_2)/2, \\ D(X) &= \mu_2 = (\theta_2 - \theta_1)^2/12. \end{aligned}$$

解此方程组得

$$\theta_1 = \alpha_1 - \sqrt{3\mu_2}, \quad \theta_2 = \alpha_1 + \sqrt{3\mu_2}.$$

将上式中 α_1 和 μ_2 分别用 \bar{X} 和 m_{n2} 代入得

$$\begin{aligned} \hat{\theta}_1(X_1, \dots, X_n) &= \bar{X} - \sqrt{3m_{n2}} = \bar{X} - \sqrt{3}S_n, \\ \hat{\theta}_2(X_1, \dots, X_n) &= \bar{X} + \sqrt{3}S_n, \end{aligned}$$

其中 S_n^2 由 (3.4) 给出 (亦可用 S 代替 S_n , 此处 S^2 由公式 (3.5) 给出).

例4. 设总体分布有概率密度

$$f_\theta(x) = \begin{cases} 2\sqrt{\frac{\theta}{\pi}} \exp\{-\theta x^2\} & \text{当 } x > 0 \\ 0 & \text{当 } x \leq 0, \end{cases}$$

其中 $\theta > 0$ 为未知参数. 这个分布称为 Maxwell 分布, 在气体分子动力学中有应用. 设 X_1, \dots, X_n 为抽自此总体的简单随机样本, 求 $g(\theta) = 1/\theta$ 的矩估计量.

解 由方程

$$\alpha_1 = E(X) = 2\sqrt{\frac{\theta}{\pi}} \int_0^{\infty} x e^{-\theta x^2} dx = \frac{1}{\sqrt{\pi\theta}}$$

解得 $g(\theta) = 1/\theta = \pi\alpha_1^2$, 将 α_1 用 \bar{X} 代替得

$$\hat{g}_1(X_1, \dots, X_n) = \pi \bar{X}^2.$$

另一方面, 由另一方程

$$\alpha_2 = E_\theta(X^2) = 2\sqrt{\frac{\theta}{\pi}} \int_0^{\infty} x^2 e^{-\theta x^2} dx = \frac{1}{2\theta}$$

解得 $g(\theta) = 1/\theta = 2\alpha_2$, 将 α_2 用 $a_{n2} = \frac{1}{n} \sum_{i=1}^n X_i^2$ 代入, 得 $g(\theta)$ 的矩估计

$$\hat{g}_2(X_1, \dots, X_n) = 2a_{n2} = \frac{2}{n} \sum_{i=1}^n X_i^2.$$

由此可见矩估计量不唯一, 但它们同样合理. 这两个矩估计量 $\hat{g}_1(\mathbf{X})$ 和 $\hat{g}_2(\mathbf{X})$ 中哪一个更好? 以后我们将证明基于 a_{n2} 的估计量 $\hat{g}_2(\mathbf{X})$, 在 $g(\theta)$ 一切无偏估计类中为方差最小者. 基于 a_{n1} 的估计 $\hat{g}_1(\mathbf{X})$ 不是 $g(\theta)$ 的无偏估计.

例5. 设总体分布有概率密度

$$f_\theta(x) = \begin{cases} \frac{\theta_2}{\Gamma((1+\theta_1)/\theta_2)} x^{\theta_1} \exp\{-x^{\theta_2}\} & x > 0 \\ 0 & x \leq 0, \end{cases}$$

参数 $\theta = (\theta_1, \theta_2)$ 的变化范围 $-1 < \theta_1 < \infty$, $\theta_2 > 0$. 设 X_1, \dots, X_n 为抽自此总体的简单随机样本, 求 θ_1 和 θ_2 的矩估计量.

解 由简单计算得到总体分布的前两阶矩为:

$$\begin{aligned} \alpha_1 &= \Gamma\left(\frac{2+\theta_1}{\theta_2}\right) / \Gamma\left(\frac{1+\theta_1}{\theta_2}\right), \\ \alpha_2 &= \Gamma\left(\frac{3+\theta_1}{\theta_2}\right) / \Gamma\left(\frac{1+\theta_1}{\theta_2}\right). \end{aligned} \quad (3.9)$$

按矩估计方法, 用 a_{n1} 和 a_{n2} 分别代替 (3.9) 中的 α_1 和 α_2 , 用 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 分别代替 θ_1 和 θ_2 , 得到如下的方程组:

$$\begin{aligned} a_{n1} &= \Gamma\left(\frac{2+\hat{\theta}_1}{\hat{\theta}_2}\right) / \Gamma\left(\frac{1+\hat{\theta}_1}{\hat{\theta}_2}\right), \\ a_{n2} &= \Gamma\left(\frac{3+\hat{\theta}_1}{\hat{\theta}_2}\right) / \Gamma\left(\frac{1+\hat{\theta}_1}{\hat{\theta}_2}\right). \end{aligned}$$

其解就是 θ_1 和 θ_2 的矩估计. 但此处得不出 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 的解析表达式, 而只能用数值方法. 此例说明不是所有的矩估计都有解析表达式的.

矩估计方法也可以用于多维样本, 请看下例.

例6. 设 (X_i, Y_i) , $i = 1, 2, \dots, n$ 为从一个二维总体中抽取的简单随机样本, 求总体分布的协方差 σ_{12} 和相关系数 ρ 的矩估计.

解 按定义 σ_{12} 的矩估计量是样本协方差, 即

$$m_{12} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}), \quad (3.10)$$

其中 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $\bar{Y} = \frac{1}{n} \sum_{j=1}^n Y_j$, 而 ρ 的矩估计量是样本相关系数, 即

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{j=1}^n (Y_j - \bar{Y})^2}}. \quad (3.11)$$

三、矩估计的无偏性

矩法是由K. Pearson 1894年提出的点估计的古老方法. 它的特点是直观性强, 用此法获得估计量简便、易行, 且不要求事先知道总体的分布, 矩估计量还具有相合性. 它的缺点是: 在参数分布族场合, 没有充分利用其提供的有关参数的信息, 小样本性质不突出. 此外, 矩估计量不具唯一性.

下面我们研究矩估计的下列三方面的性质: 小样本性质有无偏性, 大样本性质有相合性和渐近正态性. 其大样本性质将放在下段考虑.

估计量的无偏性和渐近无偏性的定义在§3.1中已给出, 下面讨论矩估计的无偏性和渐近无偏性.

(1) 样本的 k 阶原点矩 a_{nk} 是总体 k 阶原点矩 α_k ($k = 1, 2, \dots$)的无偏估计, 公式(3.3)已给出了证明.

(2) 对 $k \geq 2$, 样本的 k 阶中心矩不是总体 k 阶中心矩的无偏估计.

(i) 由例3.2.1可知

$$E(m_{n2}) = \frac{n-1}{n} \mu_2,$$

将其修正, 得

$$S^2 = \left(\frac{n}{n-1}\right) m_{n2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

是 μ_2 的无偏估计.

(ii) 经过计算可知样本的3阶中心矩 m_{n3} 也不是总体3阶中心矩 μ_3 的无偏估计, 事实上

$$E(m_{n3}) = \frac{(n-1)(n-2)}{n^2} \mu_3. \quad (3.12)$$

将其修正, 得

$$m_{n3}^* = \frac{n^2}{(n-1)(n-2)} m_{n3},$$

它是 μ_3 的无偏估计.

(iii) 更进一步, 可以证明对 $\nu \geq 4$ 有

$$E(m_{n\nu}) = \mu_\nu + O(1/n), \quad (3.13)$$

因此对 $\nu \geq 4$, $m_{n\nu}$ 也不是总体的 ν 阶中心矩 μ_ν 的无偏估计.

(3) 矩估计一般具有渐近无偏性. 由(2)可见 $m_{n\nu}$ ($\nu \geq 2$)是总体 ν 阶中心矩 μ_ν 的渐近无偏估计. 如

$$\lim_{n \rightarrow \infty} E(m_{n3}) = \lim_{n \rightarrow \infty} \frac{(n-1)(n-2)}{n^2} \mu_3 = \mu_3.$$

例7. 设 X_1, \dots, X_n i.i.d. \sim 指数分布 $EP(\lambda)$, 其密度为 $f_\lambda(x) = \lambda e^{-\lambda x} I_{[x>0]}$. 求 λ 的矩估计量 $\hat{\lambda}$, 并讨论它的无偏性.

解 由于 $\alpha_1 = \int_0^\infty x f_\lambda(x) dx = 1/\lambda$, 解得 $\lambda = 1/\alpha_1$, 将 α_1 用其矩估计量 $\bar{X} = a_{n1}$ 代入, 得到 λ 的矩估计量为

$$\hat{\lambda}(X_1, \dots, X_n) = 1/\bar{X}.$$

由于 $Y = \sum_{i=1}^n X_i \sim \text{Gamma分布 } G(n, \lambda)$,

$$E(\hat{\lambda}) = nE(1/Y) = n \int_0^\infty \frac{1}{y} \cdot \frac{\lambda^n}{\Gamma(n)} y^{n-1} e^{-\lambda y} dy = n\lambda/(n-1),$$

可见 $\hat{\lambda}(X_1, \dots, X_n) = 1/\bar{X}$ 不是 λ 的无偏估计. 因此矩估计量不一定都具有无偏性. 但 $\lim_{n \rightarrow \infty} E(\hat{\lambda}) = \lim_{n \rightarrow \infty} [n/(n-1) \cdot \lambda] = \lambda$, 故 $\hat{\lambda}(X_1, \dots, X_n)$ 是 λ 的渐近无偏估计. 对 $\hat{\lambda}$ 略作修正, 可得 λ 的一个无偏估计

$$\hat{\lambda}^*(X_1, \dots, X_n) = (n-1)\hat{\lambda}(X_1, \dots, X_n)/n = (n-1)/(n\bar{X}).$$

四、矩估计的相合性和渐近正态性

1. 矩估计的相合性

估计量的几种相合性的定义已在 §3.1 中给出. 一般说来矩估计在较一般的条件下具有相合性. 此处我们给出矩估计的强相合性, 显然相应的矩估计的弱相合性也成立.

(1) 样本 k 阶原点矩是总体 k 阶原点矩的强相合估计. 设 X_1, \dots, X_n 是从总体 F 中抽取的简单随机样本, a_{nk} 为样本的 k 阶原点矩, α_k 为总体的 k 阶原点矩. 由独立同分布场合的柯尔莫哥洛夫强大数律可知 $a_{nk} \xrightarrow{a.s.} \alpha_k, k = 1, 2, \dots$. 即

$$P\left(\lim_{n \rightarrow \infty} a_{nk} = \alpha_k\right) = 1, \quad k = 1, 2, \dots$$

(2) 样本 k 阶中心矩是总体 k 阶中心矩的强相合估计. 这一结论的证明用到下列事实(A):

(A) 设函数 $f(y_1, \dots, y_k)$ 在 (c_1, c_2, \dots, c_k) 处连续, 若 $y_{n1} \xrightarrow{a.s.} c_1, \dots, y_{nk} \xrightarrow{a.s.} c_k$, 则 $f(y_{n1}, \dots, y_{nk}) \xrightarrow{a.s.} f(c_1, c_2, \dots, c_k)$.

这一事实的证明留作练习. 我们在事实(A)成立的前提下, 证明上述结论: 由于

$$\mu_k = \sum_{r=0}^k (-1)^{k-r} \binom{k}{r} \alpha_k \alpha_1^{k-r} = f(\alpha_1, \alpha_2, \dots, \alpha_k),$$

显见 $f(\cdot)$ 是其变元的连续函数. 由(1)可知 $a_{ni} \xrightarrow{a.s.} \alpha_i, i = 1, \dots, k$, 故由上述事实(A)及公式(3.6)立得

$$m_{nk} = f(a_{n1}, \dots, a_{nk}) \xrightarrow{a.s.} f(\alpha_1, \dots, \alpha_k) = \mu_k, \quad k = 1, 2, \dots,$$

这就证明了结论.

(3) 设 $g(\theta)$ 有(??)形式, 其矩估计为(??), 关于此类矩估计的强相合性有下述定理.

定理 1. 设 $\mathbf{X} = (X_1, \dots, X_n)$ 为从总体 F 中抽取的简单随机样本, 待估函数 $g(\theta) = G(\alpha_1, \dots, \alpha_k, \mu_2, \dots, \mu_s)$, 其矩估计量为 $\hat{g}_n(\mathbf{X}) = G(a_{n1}, \dots, a_{nk}, m_{n2}, \dots, m_{ns})$, 且 G 为其变元的连续函数, 则 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta)$ 之强相合估计.

证 由(1)可知 $a_{ni} \xrightarrow{a.s.} \alpha_i, i = 1, 2, \dots$. 由(2)可知 $m_{ni} \xrightarrow{a.s.} \mu_i, i = 2, 3, \dots$. 再由 G 是其变元的连续函数, 利用事实(A), 立即可得 $\hat{g}_n(\mathbf{X}) \xrightarrow{a.s.} g(\theta)$.

由这一定理可得出一些常见估计的相合性. 例如正态总体 $N(a, \sigma^2)$ 中, 样本均值 \bar{X} 和样本方差 S^2 分别是 a 和 σ^2 的强相合估计. 也不难证明 S^2 是 σ^2 的均方相合估计. 其实对任何 $r > 0$, S^2 是 σ^2 的 r 阶矩相合估计. 例3.2.5中定义的偏度、峰度和变异系数的矩估计都是强相合的.

2. 矩估计的渐近正态性

本段我们将在很一般的条件下, 给出矩估计是相合渐近正态估计. 下面首先给出定义

定义 2. 设 $\mathbf{X} = (X_1, \dots, X_n)$ 是从总体 $\{F_\theta, \theta \in \Theta\}$ 中抽取的简单样本, $\hat{g}_n(\mathbf{X})$ 是 $g(\theta)$ 的矩估计量. 若存在与样本大小 n 有关的, 定义于参数空间 Θ 上的函数 $A_n(\theta)$ 和 $B_n(\theta)$, 其中 $B_n(\theta)$ 在 Θ 上处处大于0, 使当 $n \rightarrow \infty$ 时

$$(\hat{g}_n(\mathbf{X}) - A_n(\theta)) / B_n(\theta) \xrightarrow{\mathcal{L}} N(0, 1)$$

且 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的弱相合估计, 则称 $\hat{g}(\mathbf{X})$ 为 $g(\theta)$ 的相合渐近正态估计 (*Consistent Asymptotic Normal Estimation*, 简记为CAN估计).

就是说CAN估计是既相合, 其分布又渐近服从正态分布的那种估计. 本段我们提出两个重要结果, 即在很一般的条件下, 矩估计为CAN估计.

Delta 方法 假设 $\phi: D \subset R^k \mapsto R^m$ 为一定义在 R^k 的子集 D 上的映射, 且在 $\theta(\theta \in R^k)$ 处可微. 假设 T_n 为一列取值于 D 上的随机向量, 且存在正的趋于无穷的常数数列 r_n 使得 $r_n(T_n - \theta) \xrightarrow{d} T$, 则

$$r_n[\phi(T_n) - \phi(\theta)] \xrightarrow{d} \phi'(\theta)T.$$

其中 $\phi'(\theta)$ 为函数 ϕ 在 θ 处的 $m \times k$ 的导数矩阵.

特别, 若 $T \sim N(0, A)$, 则可以得出 $\phi'(\theta)T \sim N(0, \phi'(\theta)A[\phi'(\theta)]^T)$. 使用此方法可以证明如下结论.

(1) 设样本 X_1, \dots, X_n 为从总体 $\{F_\theta, \theta \in \Theta\}$ 中抽取的简单样本, $g(\theta)$ 是定义在参数空间 Θ 上的实函数, 它可以表为形式: $g(\theta) = G(\alpha_1, \dots, \alpha_k)$ (若 G 是 $\alpha_1, \dots, \alpha_k, \mu_1, \dots, \mu_s$ 的函数, 不妨令 $s \leq k$, 可将 μ_j 用 $\alpha_1, \alpha_2, \dots, \alpha_s$ 表出, 则 G 仍可表为 $\alpha_1, \dots, \alpha_k$ 的函数), 而 $\hat{g}(\mathbf{X}) = \hat{g}(X_1, \dots, X_n) = G(a_{n1}, \dots, a_{nk})$ 为 $g(\theta)$ 的矩估计. 再设总体的 $2k$ 阶原点矩存在, 且 G 对其各变元的一阶偏导数存在、连续, 令

$$\begin{aligned} b_{ij} &= \alpha_{i+j} - \alpha_i \alpha_j, \quad i, j = 1, 2, \dots, k; \quad B = (b_{ij}) \text{ 为 } k \times k \text{ 的方阵,} \\ d_i &= \frac{\partial G(\alpha_1, \dots, \alpha_k)}{\partial \alpha_i}, \quad i = 1, 2, \dots, k; \quad d = (d_1, \dots, d_k)' \\ b^2 &= d' B d. \end{aligned}$$

定理 2. 在上述记号和条件下, $\hat{g}_n(\mathbf{X})$ 为 $g(\theta) = G(\alpha_1, \dots, \alpha_k)$ 的CAN估计. 即 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta)$ 的弱相合估计, 且有

$$\sqrt{n}(\hat{g}_n(\mathbf{X}) - G(\alpha_1, \dots, \alpha_k)) \xrightarrow{\mathcal{L}} N(0, b^2), \quad \text{当 } n \rightarrow \infty \text{ 时}$$

证 由定理3.2.1可知 $\hat{g}_n(\mathbf{X})$ 为 $g(\theta) = G(\alpha_1, \dots, \alpha_k)$ 的强相合估计. 其渐近正态性的证明见参考文献[2] P₈₂ 定理2.6.

(2) 在一些情况下, $g(\theta)$ 可表为一、两个中心矩的函数, 还可能包含总体均值 α_1 , $g(\theta)$ 的表达式较简单. 若将中心矩用原点矩表出, $g(\theta)$ 的表达式则显得复杂, 因此有必要给出这种情形下渐近正态性的结果. 一般, 将 $g(\theta)$ 表达成如下形式

$$g(\theta) = H(\alpha_1, \mu_{t_2}, \dots, \mu_{t_r}), \quad (3.14)$$

其矩估计量为 $H(\bar{X}, m_{nt_2}, \dots, m_{nt_r})$, 使用与定理3.2.2类似证明方法, 可得如下结果:

定理 3. 设(3.14)式中的函数 H 在点 $(\alpha_1, \mu_{t_2}, \dots, \mu_{t_r})$ 的邻域内有一阶偏导数, 且此偏导数在点 $(\alpha_1, \mu_{t_2}, \dots, \mu_{t_r})$ 处连续, 则有

$$\sqrt{n} (H(\bar{X}, m_{nt_2}, \dots, m_{nt_r}) - H(\alpha_1, \mu_{t_2}, \dots, \mu_{t_r})) \xrightarrow{\mathcal{L}} N(0, b^2). \quad (3.15)$$

此处

$$b^2 = \sum_{i=1}^r \sum_{j=1}^r \sigma_{ij} H_i H_j, \quad (3.16)$$

其中

$$\begin{aligned} H_1 &= \frac{\partial H}{\partial \alpha_1}, \quad H_i = \frac{\partial H}{\partial \mu_{t_i}}, \quad i = 2, 3, \dots, r; \\ \sigma_{11} &= \mu_2, \quad \sigma_{1i} = \sigma_{i1} = \mu_{t_i+1} - t_i \mu_{t_i-1} \mu_2, \quad i = 2, \dots, r; \\ \sigma_{ij} &= \mu_{t_i+t_j} - t_i \mu_{t_i-1} \mu_{t_j+1} - t_j \mu_{t_i+1} \mu_{t_j-1} - \mu_{t_i} \mu_{t_j} \\ &\quad + t_i t_j \mu_2 \mu_{t_i-1} \mu_{t_j-1}, \quad i, j = 2, 3, \dots, r. \end{aligned}$$

如果 $g(\theta)$ 有 $H(\mu_{t_2}, \dots, \mu_{t_r})$ 的形状, 即与 α_1 无关, 则(3.15)仍成立, 只需把(3.16)式所确定的 b^2 改为 $\sum_{i=2}^r \sum_{j=2}^r \sigma_{ij} H_i H_j$ 即可.

例8. 继续考虑例3.2.5.被估计量 $g(\theta)$ 为偏度 β_1 , 峰度 β_2 和变异系数 V , 其矩估计量由例3.2.6可知为

$$\hat{\beta}_1 = \frac{m_{n3}}{m_{n2}^{3/2}}, \quad \hat{\beta}_2 = \frac{m_{n4}}{m_{n2}^2}, \quad \hat{V} = \sqrt{m_{n2}} / \bar{X}.$$

讨论它们的渐近正态性.

解 按(3.15)和(3.16)式, 对这三个矩估计量分别算得 b^2 之值为

$$b^2(\beta_1) = 6, \quad b^2(\beta_2) = 24, \quad b^2(V) = V^2/2 + V^4.$$

于是根据定理3.2.3有

$$\begin{aligned} \sqrt{n}(\hat{\beta}_1 - \beta_1) &\xrightarrow{\mathcal{L}} N(0, 6), \\ \sqrt{n}(\hat{\beta}_2 - \beta_2) &\xrightarrow{\mathcal{L}} N(0, 24), \\ \sqrt{n}(\hat{V} - V) &\xrightarrow{\mathcal{L}} N(0, V^2/2 + V^4). \end{aligned}$$

值得注意的是 $\hat{\beta}_1, \hat{\beta}_2$ 的极限分布的方差与被估计的参数值无关, 这点对 β_1, β_2 的大样本推断有用.